Busca Local e Algoritmo Genético para o Sequenciamento de Manutenção de Ativos: uma Análise Comparativa

Rafael Campello Soares, Arthur Rafael Silva Teixeira
Roberto Júnior Cassimiro Campolina, Lucas Araújo Campos Szuster
Universidade Federal de Minas Gerais (UFMG) – Departamento de Engenharia Elétrica
Disciplina: Fundamentos de Inteligência Artificial – Trabalho Prático 2
Belo Horizonte, MG, Brasil

Resumo Este trabalho compara três métodos de otimização — *greedy descent* com *random restart*, *simulated annealing* e algoritmo genético — aplicados ao sequenciamento de manutenção preventiva de ativos de uma concessionária de energia, formulado como a minimização do atraso ponderado total sobre permutações. Os métodos são avaliados em três instâncias ($n = 12$, $n = 50$ e $n = 150$) sob um orçamento idêntico de avaliações da função objetivo e com execuções independentes. **[PREENCHER: resumir os principais resultados quantitativos e a conclusão central]**

Palavras-chave busca local; *simulated annealing*; algoritmo genético; otimização combinatória; sequenciamento; atraso ponderado total.

1 Introdução

Uma concessionária de distribuição de energia precisa executar a manutenção preventiva de n ativos (religadores, transformadores de distribuição e chaves seccionadoras) com uma única equipe, que parte de uma base e atende um ativo por vez. Cada ativo possui posição, duração de serviço, prazo regulatório e um peso de criticidade que representa o custo por hora de atraso. A ordem de visita determina tanto o tempo gasto em deslocamentos quanto os atrasos incorridos, e o objetivo é encontrar a ordem que minimiza o atraso ponderado total.

O espaço de busca possui $n!$ soluções; para $n = 150$, esse número tem mais de 260 algarismos, o que inviabiliza qualquer enumeração. Trata-se de um problema de otimização combinatória sem restrições rígidas: toda permutação é viável e há apenas uma função de custo a minimizar. Dois critérios gulosos antagônicos — visitar o ativo mais próximo ou o mais urgente — não produzem, isoladamente, boas soluções, o que torna o problema adequado para comparar métodos de busca mais elaborados.

O objetivo do trabalho é comparar, em um problema prático de engenharia, heurísticas de busca local e uma metaheurística populacional, observando na prática o equilíbrio entre *exploração* (visitar regiões diferentes do espaço de busca) e *intensificação* (refinar soluções em uma região promissora). Os três algoritmos são:

- **(A)** *greedy descent* com *random restart*;
- **(B)** *simulated annealing*;
- **(C)** algoritmo genético (*genetic algorithm*, GA).

A comparação segue um protocolo único: o recurso contabilizado é o número de avaliações da função h, e todos os algoritmos recebem o mesmo orçamento por instância (Seção **??**). A pergunta central, a ser respondida com dados na Seção **??**, é qual a relação entre cada algoritmo e a estrutura do problema — em particular, se a recombinação do GA consegue combinar bons trechos de sequência de dois pais.

Organização. A Seção **??** apresenta a modelagem formal. A Seção **??** descreve a arquitetura do código e os três algoritmos. A Seção **??** detalha a metodologia experimental. A Seção **??** apresenta os resultados e a análise comparativa, e a Seção **??** traz as conclusões.

2 Modelagem do Problema

2.1 Dados da instância

Seja $\mathcal{A} = \{1, \ldots, n\}$ o conjunto de ativos e 0 o índice da base. Para cada ativo $j \in \mathcal{A}$ são dados a posição (x_j, y_j), a duração do serviço p_j (horas), o prazo d_j (hora-limite de conclusão) e o peso de criticidade w_j (custo por hora de atraso). A base tem posição (x_0, y_0) e $p_0 = 0$. O tempo de deslocamento entre dois pontos i e j é

$$t_{ij} = \operatorname{round}\left(\sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}\right), \qquad (1)$$

com arredondamento para o inteiro mais próximo. Esse arredondamento é necessário para que os valores de h sejam comparáveis entre grupos. A equipe não retorna à base ao final.

2.2 Espaço de estados, ações e função objetivo

- **Estado (solução candidata):** uma permutação $\pi = (\pi_1, \ldots, \pi_n)$ de $\mathcal{A}$, que representa a ordem de visita. O espaço de busca é $\mathcal{S} = S_n$, com $|\mathcal{S}| = n!$.
- **Ações:** os movimentos definidos pelos operadores de vizinhança (Seção **??**). Cada movimento transforma uma permutação em outra.
- **Restrições:** não há restrições rígidas, pois toda permutação é viável. Os prazos d_j são restrições brandas (*soft constraints*), penalizadas na função objetivo. O problema é de otimização, e não de satisfação.
- **Instante de conclusão:** com $\pi_0 = 0$ e $C_{\pi_0} = 0$,

$$C_{\pi_k} = C_{\pi_{k-1}} + t_{\pi_{k-1}\pi_k} + p_{\pi_k}. \qquad (2)$$

- **Função objetivo (*fitness*), a minimizar:** o atraso ponderado total

$$h(\pi) = \sum_{j=1}^{n} w_j \cdot \max(0,\, C_j - d_j). \tag{3}$$

- **Problema:** $\pi^\star = \arg\min_{\pi \in S_n} h(\pi)$.

Na terminologia do algoritmo genético, o **cromossomo** é a permutação completa, o **gene** é uma posição da sequência, o **alelo** é o ativo que a ocupa e a **aptidão** é $h(\pi)$. Como h mede custo, o GA busca o cromossomo de menor aptidão.

2.3 Propriedades úteis

O custo acumulado h é não decrescente ao longo do prefixo da permutação: acrescentar o $(k{+}1)$-ésimo ativo nunca reduz o atraso já acumulado pelos k primeiros. Além disso, o instante C_{π_k} depende apenas do prefixo $(\pi_1, \ldots, \pi_k)$, o que permite avaliar um movimento recalculando somente o sufixo afetado (Seção **??**).

2.4 Instâncias

Os arquivos `manutencao_*.txt` contêm n, as coordenadas da base e, para cada ativo, $(x_j, y_j, p_j, d_j, w_j)$. A Tabela **??** resume as instâncias e os valores de referência fornecidos no enunciado. O valor da instância pequena é o ótimo global, obtido por busca exata. Os demais são os melhores valores conhecidos, obtidos pelos professores com orçamento muito maior, e servem como alvo, não como meta obrigatória.

Tabela 1: Instâncias e valores de referência de h.

Instância	n	$\sum_j p_j$	Ref. h	Natureza
pequena	12	55	1 875	ótimo global
intermediária	50	239	16 332	melhor conhecido
grande	150	684	60 417	melhor conhecido

2.5 Operadores de vizinhança

Os três operadores clássicos geram sucessores de uma permutação (Figura do enunciado, exemplo com $\pi = (3, 7, 1, 5, 2, 8)$):

- **Swap (troca):** troca os ativos nas posições $i < j$. Há $\binom{n}{2} = \frac{n(n-1)}{2}$ sucessores.
- **Insertion (realocação):** remove o ativo da posição i e o reinsere na posição $j \neq i$. Há $n(n{-}1)$ movimentos, mas a realocação entre posições adjacentes coincide com um *swap* adjacente e é contada duas vezes; o número de sucessores distintos é $(n-1)^2$.
- **2-opt (inversão):** inverte o segmento entre as posições $i < j$. Há $\frac{n(n-1)}{2}$ sucessores, e a inversão de um segmento de tamanho 2 coincide com um *swap* adjacente.

A Tabela **??** apresenta o tamanho de cada vizinhança nas três instâncias. Os operadores não são equivalentes: cada um induz um conjunto distinto de sucessores e, portanto, uma superfície adaptativa diferente para o mesmo problema.

Tabela 2: Tamanho da vizinhança induzida em função de n.

Operador	Fórmula	$n = 12$	$n = 50$	$n = 150$
Swap	$n(n-1)/2$	66	1 225	11 175
Insertion	$(n-1)^2$	121	2 401	22 201
2-opt	$n(n-1)/2$	66	1 225	11 175

Na instância grande, uma varredura completa da vizinhança de *swap* consome 11 175 avaliações, cerca de 3,7% do orçamento de 300 000. Esse custo condiciona o comportamento das variantes de seleção do sucessor (Seção **??**).

3 Algoritmos

3.1 Arquitetura

Os três algoritmos são genéricos e interagem com o problema apenas por uma interface comum (Tabela **??**). Essa separação permite executar as 9 combinações (3 algoritmos × 3 instâncias) sem alterar o código dos algoritmos e centralizar a contagem de avaliações em um único ponto: cada chamada a h incrementa um contador único, inclusive a reavaliação da solução corrente.

Tabela 3: Interface entre algoritmos e problema.

Método	Papel
`solucao_aleatoria()`	gera uma permutação inicial
`h(s)`	fitness (minimização)
`sucessores(s)`	itera sobre todos os sucessores
`sucessor_aleatorio(s)`	sorteia um sucessor
`cruzamento(s1,s2)`	recombinação
`mutacao(s)`	mutação

[PREENCHER: linguagem/versão, bibliotecas, gerador aleatório e política de sementes (uma semente por execução, registrada em disco)]

3.2 Avaliação incremental

Avaliar h do zero custa $O(n)$. Ao aplicar um movimento cuja menor posição afetada é i, o prefixo $(\pi_1, \ldots, \pi_{i-1})$ permanece inalterado, de modo que $C_{\pi_{i-1}}$ e o custo acumulado até $i-1$ podem ser reaproveitados a partir de vetores de prefixo mantidos para a solução corrente. Basta recalcular o sufixo, a um custo $O(n-i+1)$. Isso vale para *swap*, *insertion* e 2-opt: mesmo que os travessias sejam simétricas, os instantes C_j dentro do trecho alterado mudam e precisam ser recalculados. A avaliação incremental não altera a contagem de avaliações, apenas o tempo de parede.

[PREENCHER: vizinhança(s) com avaliação incremental implementada, descrição do teste auto-

mático de concordância com a avaliação completa e seu resultado]

O ganho de tempo medido é reportado na Seção **??**.

3.3 (A) *Greedy descent* com *random restart*

A partir de uma permutação aleatória, o algoritmo move-se repetidamente para um sucessor que melhora h, até atingir um **ótimo local**: uma permutação sem sucessor melhor na vizinhança adotada. Ao atingir o ótimo local, aplica-se *random restart*: recomeça-se de nova permutação aleatória, preservando a melhor solução já vista, até esgotar o orçamento B. As variantes de seleção do sucessor são:

- ***Best improvement*:** varre toda a vizinhança e escolhe o melhor sucessor;
- ***First improvement*:** aceita o primeiro sucessor que melhora h;
- **Sucessor aleatório com aceitação de melhora:** sorteia um único sucessor e o aceita somente se melhorar h.

[PREENCHER: variantes efetivamente implementadas (mínimo duas) e a variante adotada nos experimentos principais, com justificativa]

Sob orçamento fixo, as variantes diferem fortemente em passos de melhoria por avaliação: o *best improvement* paga uma vizinhança inteira por passo, enquanto o *first improvement* e a variante aleatória pagam em média menos. A Seção **??** reporta quantos passos de melhoria cada variante deu dentro do orçamento. Para a variante aleatória, o critério de ótimo local não é determinístico; é preciso definir o critério de reinício.

[PREENCHER: critério de detecção de ótimo local/reinício da variante aleatória, se implementada]

3.4 (B) *Simulated annealing*

Seja π a solução corrente e π' um sucessor sorteado ao acaso. Se $h(\pi') \le h(\pi)$, aceita-se π'; caso contrário, aceita-se com probabilidade

$$P = \exp\left(-\frac{h(\pi') - h(\pi)}{T}\right), \tag{4}$$

a distribuição de Gibbs. Cada sucessor examinado consome uma avaliação.

Annealing schedule. Adota-se resfriamento geométrico $T \leftarrow \alpha T$. Como cada iteração consome uma avaliação e o orçamento é B, impor $T_f = T_0\,\alpha^{\,B/m}$ com atualização a cada m iterações fornece

$$\alpha = \left(\frac{T_f}{T_0}\right)^{m/B}. \tag{5}$$

Assim, a temperatura chega a T_f exatamente ao esgotar o orçamento, e o resfriamento é ajustado a B de cada instância.

Calibração de T_0 e T_f. A escala de T depende da magnitude típica de $h(\pi') - h(\pi)$, que varia de dezenas a milhares e muda com a instância; portanto, os parâmetros são calibrados *por instância*. O procedimento adotado deve ser:

1. amostrar um conjunto de pares (π, π') aleatórios por instância e estimar a distribuição de $\Delta = h(\pi') - h(\pi)$ para $\Delta > 0$;
2. escolher T_0 tal que a taxa de aceitação inicial de movimentos piores seja próxima de um alvo alto (quase *random walk*);
3. escolher T_f tal que a taxa de aceitação final seja praticamente nula (quase *greedy descent*);
4. verificar a escolha pelo gráfico da taxa de aceitação ao longo da execução.

[PREENCHER: alvos de aceitação, tamanho da amostra de calibração e valores finais de T_0, T_f, α e m por instância (Tabela ??)]

Tabela 4: Parâmetros do *simulated annealing* por instância.

Instância	T_0	T_f	α
pequena	**[PREENCHER]**	**[PREENCHER]**	**[PREENC**
intermediária	**[PREENCHER]**	**[PREENCHER]**	**[PREENC**
grande	**[PREENCHER]**	**[PREENCHER]**	**[PREENC**

Taxa de aceitação. Registra-se, em janelas de avaliações, a fração de movimentos *piores* aceitos. Uma têmpera bem calibrada começa quase como *random walk* e termina quase como *greedy descent*; um gráfico que permanece alto indica T alta demais, e um que cai a zero logo no início indica T baixa demais.

3.5 (C) Algoritmo genético

O GA mantém uma população de N cromossomos e repete: seleção, cruzamento com probabilidade P_c, mutação com probabilidade P_m e elitismo, até esgotar o orçamento de avaliações. A população inicial é uma amostra aleatória de N permutações.

Seleção e conversão custo→aptidão. Como h é de minimização, o operador de seleção deve favorecer valores *menores*. No torneio de tamanho k, basta escolher o indivíduo de menor h entre k sorteados, sem conversão. Na roleta, é necessária uma aptidão $f(\pi) \ge 0$ crescente com a qualidade, por exemplo $f(\pi) = h_{\max} - h(\pi)$ (com $h_{\max}$ o pior valor da geração) ou $f(\pi) = 1/(1 + h(\pi))$.

[PREENCHER: operador de seleção adotado, tamanho do torneio ou fórmula de conversão custo→aptidão efetivamente usada, e justificativa]

Cruzamento. Cruzamentos clássicos de um ou múltiplos pontos duplicariam ativos e gerariam cromossomos inválidos; é necessário um operador que preserve a permutação (OX, PMX ou cruzamento por arestas).

[PREENCHER: operador de cruzamento adotado (OX, PMX ou arestas) e justificativa]

A título de ilustração, o *Order Crossover* (OX) opera como segue, com $n = 8$, pais $P_1 = (1\,2\,3\,4\,5\,6\,7\,8)$ e $P_2 = (3\,7\,5\,1\,6\,8\,2\,4)$ e pontos de corte antes da posição 4 e depois da posição 6:

1. copia-se o segmento de P_1 entre os cortes para o filho: $(_\,_\,_\,4\,5\,6\,_\,_)$;
2. percorre-se P_2 a partir da posição seguinte ao segundo corte (posição 7), de forma circular: $2, 4, 3, 7, 5, 1, 6, 8$;
3. descartam-se os ativos já presentes no segmento $(4, 5, 6)$, restando $2, 3, 7, 1, 8$;
4. preenchem-se as posições livres a partir da posição 7, também circularmente: posições $7, 8, 1, 2, 3$ recebem $2, 3, 7, 1, 8$;
5. o filho é $(7\,1\,8\,4\,5\,6\,2\,3)$, que é uma permutação válida.

Mutação. Aplica-se uma pequena taxa de mutação para inserir diversidade e favorecer a exploração. O ponto de partida é a *swap mutation*; os demais operadores da vizinhança também são admissíveis.

[PREENCHER: operador de mutação adotado]

Elitismo e parâmetros. O elitismo preserva os e melhores indivíduos de cada geração. A Tabela **??** reúne os parâmetros. Cada indivíduo novo avaliado consome uma avaliação, e o algoritmo para exatamente em B.

Tabela 5: Parâmetros do algoritmo genético.

Parâmetro	pequena	interm.	grande
N (população)	[PREENCHER]	[PREENCHER]	[PREENCHER]
P_c	[PREENCHER]	[PREENCHER]	[PREENCHER]
P_m	[PREENCHER]	[PREENCHER]	[PREENCHER]
Elitismo (e)	[PREENCHER]	[PREENCHER]	[PREENCHER]
Tamanho do torneio	[PREENCHER]	[PREENCHER]	[PREENCHER]

[PREENCHER: como os parâmetros foram escolhidos e testados]

Diversidade. A cada geração registra-se o número de cromossomos distintos e a distância média entre pares de indivíduos, definida pela distância de Hamming entre posições $d(\pi, \sigma) = |\{k : \pi_k \neq \sigma_k\}|$. A queda dessas medidas diagnostica a convergência prematura.

4 Protocolo Experimental

4.1 Orçamento e execuções

Todos os algoritmos gastam o mesmo recurso: o número de avaliações de h. Cada sucessor examinado pela busca local conta 1, e cada indivíduo avaliado pelo GA conta 1. Os algoritmos param exatamente ao atingir o orçamento (Tabela **??**).

Tabela 6: Orçamento e execuções independentes.

Instância	Orçamento B	Execuções
pequena ($n = 12$)	50 000	30
intermediária ($n = 50$)	150 000	30
grande ($n = 150$)	300 000	10

4.2 Métricas e estatística

Para cada combinação algoritmo × instância, registra-se o melhor h de cada execução e calculam-se média, desvio-padrão, mínimo e mediana. O gap relativo ao ótimo na instância pequena é $\text{gap} = (h - h^\star)/h^\star$, com $h^\star = 1875$. Registram-se também o tempo de parede por execução e o número de avaliações.

As comparações par a par usam o teste não paramétrico de Mann–Whitney [**?**], bilateral, com nível de significância $\alpha_s = 0{,}05$. Como são três comparações por instância, sugere-se correção de Holm.

[PREENCHER: teste e correção para múltiplas comparações efetivamente usados e a biblioteca empregada]

Médias próximas com dispersões grandes não sustentam conclusão; as afirmações de superioridade no texto vêm acompanhadas do p-valor.

4.3 Curvas de convergência

Para cada instância, registra-se o melhor h encontrado em função do número de avaliações gastas, em uma grade fixa de pontos, e plota-se a mediana das execuções por algoritmo. Para o GA, acrescenta-se a curva da média da população; a distância entre as duas curvas indica a perda de diversidade.

4.4 Ambiente de execução

[PREENCHER: descrição do hardware (CPU, memória), sistema operacional e versões do interpretador/compilador usados nas medições de tempo]

4.5 Reprodutibilidade

O código acompanha um `README` com os comandos exatos para reproduzir cada tabela e figura. Os resultados brutos de todas as execuções são gravados em arquivos `.csv`.

[PREENCHER: endereço do repositório ou nome do arquivo .zip e os comandos do README para cada tabela e figura (ver Anexo A)]

5 Resultados e Análise

5.1 T1: validação da função de avaliação

A função h foi validada com os dois valores do enunciado para `manutencao_pequena.txt`: a permutação identidade $\pi = (1, \ldots, 12)$ deve resultar em $h(\pi) = 4366$, e o ótimo global conhecido é $h^\star = 1875$. Uma heurística gulosa razoável (menor acréscimo imediato de atraso) alcança 3168, cerca de 69% acima do ótimo.

Tabela 7: Saída do programa nos casos de verificação.

Caso	Esperado	Obtido
Identidade, instância pequena	4 366	[PREENCHER]
Ótimo global, instância pequena	1 875	[PREENCHER]

[PREENCHER: saída literal do programa para os dois casos; opcionalmente o exemplo com $n = 4$ (custos 39 e 22)]

5.2 T2: comparação das vizinhanças

Usando *greedy descent* com *random restart* e o mesmo orçamento, comparam-se *swap*, *insertion* e 2-opt nas três instâncias.

[PREENCHER: resultados do experimento T2]

Discussão e escolha da vizinhança. [PREENCHER: qual vizinhança conduz a melhores ótimos locais, qual é mais barata por movimento com avaliação incremental, discussão dos passos de melhoria de cada variante de seleção sob o orçamento (em especial na instância grande, onde uma varredura de *swap* custa 11 175 avaliações) e justificativa da vizinhança adotada nos demais experimentos]

5.3 Ganho da avaliação incremental

Tabela 9: Tempo de avaliação: completa vs. incremental.

Instância	Completa (s)	Incremental (s)	Ganho
pequena	[PREENCHER]	[PREENCHER]	[PREENCHER]
intermediária	[PREENCHER]	[PREENCHER]	[PREENCHER]
grande	[PREENCHER]	[PREENCHER]	[PREENCHER]

[PREENCHER: medições de tempo e comentário sobre o ganho observado por tamanho de instância]

5.4 T3: resultados principais

[PREENCHER: valores da Tabela ?? a partir dos resultados em disco]

Boxplots. A Figura ?? compara os três algoritmos em cada instância.

Curvas de convergência. A Figura ?? apresenta a mediana do melhor h em função das avaliações, e, para o GA, a curva da média da população.

Testes estatísticos.

Tabela 11: p-valores do teste de Mann–Whitney (bilateral).

Comparação	pequena	interm.	grande
Greedy vs. SA	[PREENCHER]	[PREENCHER]	[PREENCHER]
Greedy vs. GA	[PREENCHER]	[PREENCHER]	[PREENCHER]
SA vs. GA	[PREENCHER]	[PREENCHER]	[PREENCHER]

[PREENCHER: p-valores (e correção, se aplicável) e leitura de quais diferenças são estatisticamente significativas]

Tempo e avaliações. A Tabela ?? apresenta o tempo médio por execução ao lado do número de avaliações. O orçamento é igual entre algoritmos, mas o custo por avaliação não é: operadores como o cruzamento, a avaliação incremental e a manutenção de estruturas da população fazem o tempo de parede diferir mesmo com avaliações idênticas.

[PREENCHER: discussão da diferença entre as métricas (avaliações vs. tempo de parede) com base nos tempos medidos]

5.5 Discussão

Ótimos locais. [PREENCHER: número de ótimos locais distintos do *greedy descent* na instância pequena; em quantas execuções cada algoritmo atingiu $h^\star = 1875$; relação com a discussão de ótimo local × ótimo global]

Exploração × intensificação. Em cada algoritmo, identificam-se os seguintes mecanismos candidatos; a análise deve apoiá-los em dados (Seção ??):

- *Greedy + restart*: a descida intensifica; o *restart* explora.
- *Simulated annealing*: a aceitação de piores (alta T) explora; o resfriamento leva à intensificação.
- GA: o cruzamento e a mutação exploram; a seleção e o elitismo intensificam.

[PREENCHER: evidências nos dados de onde o equilíbrio foi bem ou mal ajustado: taxa de aceitação do SA (gráfico), diversidade do GA, número de reinícios do *greedy*]

[FIGURA PENDENTE]
taxa de aceitação do SA ao longo da execução (arquivo fig_aceitacao.pdf)

Figura 3: Taxa de aceitação de movimentos piores no *simulated annealing*.

[FIGURA PENDENTE]
diversidade da população do GA por geração (arquivo fig_diversidade.pdf)

Figura 4: Evolução da diversidade da população do algoritmo genético.

Efeito da escala. [PREENCHER: o ranking muda entre a instância pequena e a grande? Hipótese (se mudar) ou evidência estatística de estabilidade (se não mudar)]

Quando o algoritmo genético compensa? [PREENCHER: existe instância em que o GA supera significativamente as duas abordagens de busca local? Citar os p-valores]

Tabela 8: Comparação das vizinhanças no *greedy descent* com *random restart* (média ± desvio-padrão do melhor h por execução).

Instância	Vizinhança	Melhor h (média ± dp)	Passos de melhoria	Reinícios	Tempo por movimento (s)
pequena	Swap	[PREENCHER]	[PREENCHER]	[PREENCHER]	[PREENCHER]
pequena	Insertion	[PREENCHER]	[PREENCHER]	[PREENCHER]	[PREENCHER]
pequena	2-opt	[PREENCHER]	[PREENCHER]	[PREENCHER]	[PREENCHER]
intermediária	Swap	[PREENCHER]	[PREENCHER]	[PREENCHER]	[PREENCHER]
intermediária	Insertion	[PREENCHER]	[PREENCHER]	[PREENCHER]	[PREENCHER]
intermediária	2-opt	[PREENCHER]	[PREENCHER]	[PREENCHER]	[PREENCHER]
grande	Swap	[PREENCHER]	[PREENCHER]	[PREENCHER]	[PREENCHER]
grande	Insertion	[PREENCHER]	[PREENCHER]	[PREENCHER]	[PREENCHER]
grande	2-opt	[PREENCHER]	[PREENCHER]	[PREENCHER]	[PREENCHER]

Tabela 10: Resultados dos três algoritmos (melhor h por execução). O gap é calculated apenas na instância pequena, com $h^\star = 1875$.

Instância	Algoritmo	Média ± dp	Mediana	Mínimo	Gap	Tempo médio
pequena	Greedy + restart	[PREENCHER]	[PREENCHER]	[PREENCHER]	[PREENCHER]	[PREENCH
pequena	Sim. annealing	[PREENCHER]	[PREENCHER]	[PREENCHER]	[PREENCHER]	[PREENCH
pequena	Alg. genético	[PREENCHER]	[PREENCHER]	[PREENCHER]	[PREENCHER]	[PREENCH
intermediária	Greedy + restart	[PREENCHER]	[PREENCHER]	[PREENCHER]	—	[PREENCH
intermediária	Sim. annealing	[PREENCHER]	[PREENCHER]	[PREENCHER]	—	[PREENCH
intermediária	Alg. genético	[PREENCHER]	[PREENCHER]	[PREENCHER]	—	[PREENCH
grande	Greedy + restart	[PREENCHER]	[PREENCHER]	[PREENCHER]	—	[PREENCH
grande	Sim. annealing	[PREENCHER]	[PREENCHER]	[PREENCHER]	—	[PREENCH
grande	Alg. genético	[PREENCHER]	[PREENCHER]	[PREENCHER]	—	[PREENCH

[FIGURA PENDENTE]
boxplots do melhor h por algoritmo, um painel por instância (arquivo fig_boxplots.pdf)

Figura 1: Boxplots do melhor h encontrado por execução, por instância e algoritmo.

[FIGURA PENDENTE]
curvas de convergência por instância (arquivo fig_convergencia.pdf)

Figura 2: Curvas de convergência (mediana das execuções). A distância entre a curva do melhor e a da média da população do GA indica a perda de diversidade.

5.5.1 Experimento adicional: a recombinação combina bons trechos?

Hipótese. O GA só traz vantagem sobre a busca local se a recombinação conseguir juntar bons trechos de sequência de dois pais em um filho melhor, isto é, se a codificação por permutação preservar blocos úteis (por exemplo, subsequências de ativos com prazos próximos visitadas em boa ordem). Se o cruzamento produzir filhos em geral piores que ambos os pais, o GA funciona como uma busca aleatória guiada pela mutação e pela seleção.

Experimento proposto. Duas medidas complemen-

tares sobre o mesmo orçamento e as mesmas instâncias:

1. **Ablação:** comparar o GA completo com uma versão sem cruzamento ($P_c = 0$, apenas mutação, seleção e elitismo), com o mesmo N e B, usando Mann–Whitney sobre o melhor h final.

2. **Qualidade dos filhos:** em cada geração, registrar a fração de filhos com h menor que o de ambos os pais, menor que o do melhor pai e maior que o de ambos, e como essas frações evoluem à medida que a diversidade cai.

Tabela 12: Experimento adicional: efeito do cruzamento.

Métrica	pequena	interm.	grande
Melhor h, GA completo (média)	**[PREENCHER]**	**[PREENCHER]**	**[PREENCHER]**
Melhor h, GA sem cruzamento (média)	**[PREENCHER]**	**[PREENCHER]**	**[PREENCHER]**
p-valor (Mann–Whitney)	**[PREENCHER]**	**[PREENCHER]**	**[PREENCHER]**
Filhos melhores que ambos os pais (%)	**[PREENCHER]**	**[PREENCHER]**	**[PREENCHER]**
Filhos piores que ambos os pais (%)	**[PREENCHER]**	**[PREENCHER]**	**[PREENCHER]**

[PREENCHER: resultados do experimento e a interpretação: a hipótese foi sustentada ou refutada pelos dados?]

6 Conclusões

[PREENCHER: síntese dos resultados, lições sobre exploração e intensificação, conclusão sobre a recombinação, limitações e trabalhos futuros]

Referências

[1] D. Poole and A. Mackworth, *Artificial Intelligence: Foundations of Computational Agents*, 3rd ed. Cambridge University Press, 2023. Cap. 4.

[2] A. E. Eiben and J. E. Smith, *Introduction to Evolutionary Computing*. Springer-Verlag, 2003.

[3] A. Gaspar-Cunha, R. H. C. Takahashi, and C. H. Antunes (Orgs.), *Manual de Computação Evolutiva e Metaheurística*. Editora UFMG, 2013.

[4] S. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 3rd ed. Pearson, 2016. Cap. 4.

[5] H. B. Mann and D. R. Whitney, "On a test of whether one of two random variables is stochastically larger than the other," *Annals of Mathematical Statistics*, vol. 18, no. 1, pp. 50–60, 1947.

A Reprodução dos resultados

Tabela 13: Mapa de reprodução (tabelas e figuras → comandos).

Item	Comando
Tabela ?? (T1)	**[PREENCHER]**
Tabela ?? (T2)	**[PREENCHER]**
Tabela ??	**[PREENCHER]**
Tabela ??	**[PREENCHER]**
Tabela ??	**[PREENCHER]**
Tabela ??	**[PREENCHER]**
Figura ??	**[PREENCHER]**
Figura ??	**[PREENCHER]**
Figura ??	**[PREENCHER]**
Figura ??	**[PREENCHER]**